

Wissenschaftliches Rechnen - Großübung 6.2

Themen: Newton-Verfahren, Lagrange-Multiplikatoren

Ugo & Gabriel

7. Februar 2023

Aufgabe 1: Newton-Verfahren

1. Wie lautet der Iterationsschritt des Newton-Verfahrens zum Finden von Optima einer mehrdimensionalen Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}$?

_____ Lösung _____

$$\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t - \mathbf{H}_f^{-1}(\mathbf{x}_t) \nabla f(\mathbf{x}_t)$$

_____ Lösung Ende _____

2. Welche geometrische Bedeutung hat ein Iterationsschritt des Newton-Verfahrens?

_____ Lösung _____

Wir führen eine Taylorapproximation 2. Ordnung T_2 für die Funktion f am Punkt \mathbf{x}_t durch. Der neue Punkt \mathbf{x}_{t+1} ist der bzw. ein kritischer Punkt von T_2 .

_____ Lösung Ende _____

3. Der Iterationsschritt hängt von der Hessematrix des aktuellen Zustandes ab. Wie verhält sich das Verfahren, wenn die Hessematrix

- a) positiv definit ist?
- b) negativ definit ist?
- c) indefinit, aber regulär ist?

_____ Lösung _____

- a) Falls \mathbf{H}_f positiv definit ist, so ist T_2 konvex und der neue Punkt ist das Minimum von T_2 .
- b) Falls \mathbf{H}_f negativ definit ist, so ist T_2 konkav und der neue Punkt dessen Maximum.
- c) Falls \mathbf{H}_f indefinit (und regulär) ist, so ist der Sattelpunkt von T_2 der neue Punkt.

_____ Lösung Ende _____

4. Wie lautet der Iterationsschritt des Gradientenabstiegsverfahrens (Gradient Descent)?

_____ Lösung _____

$$\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t - \alpha \nabla f(\mathbf{x}_t)$$

_____ Lösung Ende _____

5. Unter welchen Umständen verhält sich das Gradientenverfahren wie das Newton-Verfahren?

— Lösung —

Die Verfahren verhalten sich gleich, falls f eine konstante Hessematrix mit $\mathbf{H}_f(\mathbf{x}) = \frac{1}{\alpha} \mathbf{I}$ hat. Somit ist f eine quadratische Funktion, dessen Niveaumengen Kreise sind.

— Lösung Ende —

6. Nun möchten wir untersuchen, wie sich das Newton-Verfahren sowie das Gradientenabstiegsverfahren bei einer affinen¹ Koordinatentransformation $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ mit $T(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ verhalten, wobei $\mathbf{A} \in \mathbb{R}^{n \times n}$ regulär ist und $\mathbf{b} \in \mathbb{R}^n$. Zeigen Sie, dass das Newton-Verfahren invariant bezüglich besagter Transformation ist, das Gradientenverfahren hingegen nicht.

Hinweis: Sie sollen untersuchen, ob $T(\mathbf{y}_{t+1}) = \mathbf{x}_{t+1}$, falls $T(\mathbf{y}_t) = \mathbf{x}_t$.

— Lösung —


Zunächst schauen wir uns an, wie der Gradient und die Hessematrix sich unter affinen Transformationen verhalten. Seien $\mathbf{x}_t = \mathbf{A}\mathbf{y}_t + \mathbf{b}$ sowie $g(\mathbf{y}) = f(\mathbf{A}\mathbf{y} + \mathbf{b})$. Es gilt:

$$\nabla g(\mathbf{y}) = \mathbf{A}^\top \nabla f(\mathbf{A}\mathbf{y} + \mathbf{b}) \quad \mathbf{H}_g(\mathbf{y}) = \mathbf{A}^\top \mathbf{H}_f(\mathbf{A}\mathbf{y} + \mathbf{b}) \mathbf{A}$$

Ferner ist dann:

$$\begin{aligned} T(\mathbf{y}_{t+1}) &= \mathbf{A}(\mathbf{y}_t - \Delta \mathbf{y}_t) + \mathbf{b} \\ &= \mathbf{A}\mathbf{y}_t - \mathbf{A}\Delta \mathbf{y}_t + \mathbf{b} \\ &= \mathbf{A}\mathbf{x}_t + \mathbf{b} - \mathbf{A}\mathbf{H}_g^{-1}(\mathbf{y}_t) \nabla g(\mathbf{y}_t) \\ &= \mathbf{A}\mathbf{y}_t + \mathbf{b} - \mathbf{A}(\mathbf{A}^\top \mathbf{H}_f(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \mathbf{A})^{-1} \mathbf{A}^\top \nabla f(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \\ &= \mathbf{A}\mathbf{y}_t + \mathbf{b} - \mathbf{A}\mathbf{A}^{-1} \mathbf{H}_f^{-1}(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \mathbf{A}^{-\top} \mathbf{A}^\top \nabla f(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \\ &= \mathbf{A}\mathbf{y}_t + \mathbf{b} - \mathbf{H}_f^{-1}(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \nabla f(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \\ &= \mathbf{x}_t - \mathbf{H}_f^{-1}(\mathbf{x}_t) \nabla f(\mathbf{x}_t) \\ &= \mathbf{x}_{t+1} \end{aligned}$$

Interpretation des Ergebnisses: Das Newton-Verfahren kann durch einen Koordinatenwechsel nicht verbessert werden. Hier ein Diagramm dazu:



¹Eine affine Transformation entspricht einer linearen Transformation gefolgt von einer Translation.

Das Gradientenverfahren ist nicht invariant bzgl. affinen Transformationen.

$$\begin{aligned}T(\mathbf{y}_{t+1}) &= \mathbf{A}(\mathbf{y}_t - \alpha \nabla g(\mathbf{y}_t)) + \mathbf{b} \\&= \mathbf{A}\mathbf{y}_t + \mathbf{b} - \alpha \mathbf{A} \nabla g(\mathbf{y}_t) \\&= \mathbf{A}\mathbf{y}_t + \mathbf{b} - \alpha \mathbf{A} \mathbf{A}^\top \nabla f(\mathbf{A}\mathbf{y}_t + \mathbf{b}) \\&= \mathbf{x}_t - \alpha \mathbf{A} \mathbf{A}^\top \nabla f(\mathbf{x}_t) \\&\neq \mathbf{x}_{t+1}\end{aligned}$$

Lösung Ende

Aufgabe 2: Lagrange-Multiplikatoren

1. Wir haben einen 100 m langen Metalldraht, welchen wir zu einem rechteckigen Zaun mit den Seitenlängen x und y und maximaler Fläche spannen wollen. Das kann man als folgendes Optimierungsproblem schreiben:

$$\max \quad xy \quad \text{s.t.} \quad 2x + 2y = 100$$

Die Funktion $f(x, y) = xy$ beschreibt die Fläche und die Funktion $g(x, y) = 2x + 2y$ beschreibt den Umfang.

- Lösen Sie das Problem ohne Verwendung von Lagrange-Multiplikatoren.
- Lösen Sie das Problem mithilfe von Lagrange-Multiplikatoren.

Lösung

- Wir können y als Funktion von x darstellen und dies in die Zielfunktion einsetzen. Wir erhalten $y = 50 - x$ und die neue (eindimensionale) Zielfunktion $f(x) = x(50 - x)$. Diese leiten wir ab: $f'(x) = 50 - 2x$. Der einzige Kandidat ist $x = 25$. Wegen der zweiten Ableitung $f''(x) = -2$ wissen wir, dass es sich dabei um ein Maximum handelt. Aus $x = 25$ können wir y rekonstruieren, nämlich $y = 50 - x = 50 - 25 = 25$. Somit sollte der Zaun quadratisch sein.
- Wir definieren die Lagrange-Funktion:

$$\mathcal{L}(x, y, \lambda) = f(x, y) - \lambda(g(x, y) - c) = xy - \lambda(2x + 2y - 100)$$

Diese leiten wir partiell ab und erhalten nach Gleichsetzen mit Null folgendes Gleichungssystem:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x} &= y - 2\lambda = 0 \\ \frac{\partial \mathcal{L}}{\partial y} &= x - 2\lambda = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} &= 2x + 2y - 100 = 0 \end{aligned}$$

Aus den ersten zwei Bedingungen erhalten wir $x = y$. Setzen wir das in die Nebenbedingung (also die dritte Gleichung) ein, erhalten wir $4x = 100$, also $x = 25$ und damit auch $y = 25$.

Das Folgende geht über den Stoff dieses Moduls hinaus:

Zu überprüfen, ob der kritische Punkt (x^*, y^*) ein Minimum, Maximum oder Sattelpunkt unter der Nebenbedingung ist, ist mithilfe des üblichen Kriteriums (Definitheit der Hessematrix) nicht möglich. Dazu gibt es ein anderes Kriterium, mit der sogenannten Bordered Hessian:

$$\mathbf{H}_{\mathcal{L}}(\mathbf{x}, \lambda) = \begin{bmatrix} \frac{\partial^2 \mathcal{L}}{\partial \lambda^2} & \frac{\partial^2 \mathcal{L}}{\partial \lambda \partial \mathbf{x}} \\ \left(\frac{\partial^2 \mathcal{L}}{\partial \lambda \partial \mathbf{x}} \right)^T & \frac{\partial^2 \mathcal{L}}{\partial \mathbf{x}^2} \end{bmatrix} = \begin{bmatrix} 0 & \frac{\partial g}{\partial \mathbf{x}} \\ \left(\frac{\partial g}{\partial \mathbf{x}} \right)^T & \frac{\partial^2 \mathcal{L}}{\partial \mathbf{x}^2} \end{bmatrix}$$

Aufgrund der Null bzw. des Nullblocks bei mehreren Bedingungen ist die Matrix niemals positiv definit bzw. negativ definit. Stattdessen lautet das Kriterium:

- Falls ihre Determinante positiv ist, so ist der kritische Punkt ein lokales Maximum.

- Falls ihre Determinante negativ ist, so ist der kritische Punkt ein lokales Minimum. Achtung: Hier ist es, anders als beim üblichen Kriterium, nicht umgekehrt.

Die Bordered Hessian für unser Problem ist folgende konstante Matrix:

$$\mathbf{H}_{\mathcal{L}} = \begin{bmatrix} 0 & 2 & 2 \\ 2 & 0 & 1 \\ 2 & 1 & 0 \end{bmatrix}$$

Ihre Determinante ist 8, also ist der Punkt ein lokales Maximum.

Lösung Ende

2. Wie kann man das folgende Optimierungsproblem mithilfe von Lagrange-Multiplikatoren lösen, obwohl die Nebenbedingung keine Gleichung ist?

$$\min \quad x^2 - xy + y \quad \text{s.t.} \quad x^2 + y^2 \leq 9$$

Lösung

Die Nebenbedingung ist eine Ungleichung und beschreibt eine Kreisscheibe mit Mittelpunkt $(0,0)$ und Radius 3 in der Ebene. Dieses Problem lässt sich in zwei separate Probleme umwandeln:

- Wir finden alle kritischen Punkte ohne Nebenbedingung durch $\nabla f(x,y) = (0,0)$, wobei $f(x,y) = x^2 - xy + y$. Wir überprüfen für jeden normalen kritischen Punkt, ob er die Nebenbedingung erfüllt, also im Inneren des Kreises ist.
- Wir finden alle kritischen Punkte unter der Nebenbedingung $x^2 + y^2 = 9$ mithilfe von Lagrange-Multiplikatoren.

Dann setzen wir alle Punkte in die Zielfunktion f ein. Das Minimum unter ihnen ist der gesuchte Punkt.

Hinweis: In diesem Fall beschreibt die Bedingung eine kompakte Menge, sodass unter den gefundenen Punkten tatsächlich das globale Minimum (und sogar das globale Maximum) vorhanden ist (vgl. Satz vom Minimum/Maximum). Das muss im Allgemeinen nicht der Fall sein.

Lösung Ende

3. Wir betrachten folgendes Optimierungsproblem:

$$\max \quad \mathbf{x}^T \mathbf{A} \mathbf{x} \quad \text{s.t.} \quad \|\mathbf{x}\| = 1$$

Dabei ist $\mathbf{A} \in \mathbb{R}^{n \times n}$ eine symmetrische, positiv semidefinite Matrix und $\|\cdot\|$ die ℓ^2 -Norm.

- Um welches Ihnen wohlbekannte Problem handelt es sich hierbei?
- Schreiben Sie die Nebenbedingung um, sodass sie keine Wurzel mehr enthält. Warum ist dies nützlich?
- Geben Sie eine Lagrange-Funktion zum Problem an.
- Geben Sie die notwendige Bedingung für einen kritischen Punkt unter der Nebenbedingung an.
- Warum befindet sich das globale Minimum sowie das globale Maximum garantiert unter den kritischen Punkten?

- f) Welcher Vektor $\mathbf{x} \in \mathbb{R}^n$ löst das Optimierungsproblem? Was ist der zugehörige Funktionswert?

Lösung

- a) Hauptkomponentenanalyse (PCA)
b) $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x} = 1$
c) $\mathcal{L}(\mathbf{x}, \lambda) = \mathbf{x}^T \mathbf{A} \mathbf{x} + \lambda(1 - \mathbf{x}^T \mathbf{x})$
d) Es gilt:

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \mathbf{x}} &= 2\mathbf{A} \mathbf{x} - 2\lambda \mathbf{x} = \mathbf{0} \\ \Leftrightarrow 2\mathbf{A} \mathbf{x} &= 2\lambda \mathbf{x} \\ \Leftrightarrow \mathbf{A} \mathbf{x} &= \lambda \mathbf{x}\end{aligned}$$

Jeder kritische Punkt unter der Nebenbedingung ist ein Eigenvektor von \mathbf{A} .

- e) Die Nebenbedingung beschreibt eine Sphäre (Rand einer Kugel) im \mathbb{R}^n , welche eine kompakte Menge ist. Stetige Funktionen auf kompakten Mengen nehmen ihr globales Minimum sowie Maximum an.
f) Sei \mathbf{x} ein Eigenvektor von \mathbf{A} . Es gilt:

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda$$

Da wir unter den kritischen Punkten den Eigenwert maximieren, ist die Lösung zu unserem Problem der Eigenvektor \mathbf{v}_1 zum größten Eigenwert von \mathbf{A} .

Lösung Ende
