

Hanno Gottschalk Institute of Mathematics, TU Berlin Stochastik für Informatik | SoSe2023, TU Berlin | 27. Juni 2023



► Konsistente Schätzer sind in der Praxis nur Approximationen. Aber wie gut sind diese?



- ► Konsistente Schätzer sind in der Praxis nur Approximationen. Aber wie gut sind diese?
- ► Wie groß muss eine Stichprobe sein, dass diese Approximation hinreichend gut wird?



- ► Konsistente Schätzer sind in der Praxis nur Approximationen. Aber wie gut sind diese?
- ► Wie groß muss eine Stichprobe sein, dass diese Approximation hinreichend gut wird?
- ▶ Mit welchem Schätzfehler muss man bei gegebener Stichprobengröße rechnen?



- ► Konsistente Schätzer sind in der Praxis nur Approximationen. Aber wie gut sind diese?
- ► Wie groß muss eine Stichprobe sein, dass diese Approximation hinreichend gut wird?
- ▶ Mit welchem Schätzfehler muss man bei gegebener Stichprobengröße rechnen?

Wir geben uns eine W.-keit $\alpha \in (0,1)$ vor und konstruieren ein Intervall um einen Schätzwert, sodass der wahre Wert mit W.-keit $1-\alpha$ in diesem Intervall liegt.



Sei $(\Omega, \{P_{\theta}\}_{\theta \in \Theta}, \{X_j\}_{j \in \mathbb{N}})$ ein statistisches Modell und θ_j die j-te Komponente von $\theta = (\theta_1, \dots, \theta_g)$.



Sei $(\Omega, \{P_{\theta}\}_{\theta \in \Theta}, \{X_j\}_{j \in \mathbb{N}})$ ein statistisches Modell und θ_j die j-te Komponente von $\theta = (\theta_1, \dots, \theta_g)$.

(i) Es seien S_-, S_+ zwei Schätzer und $\alpha \in (0,1)$ eine (kleine) Irrtumswahrscheinlichkeit. Falls $S_- \leq S_+$ und

$$P_{\theta}(\theta_{j} \in (S_{-}, S_{+}])$$

$$= P_{\theta}(\{S_{-}(X_{1}, ..., X_{n}) < \theta_{j} \le S_{+}(X_{1}, ..., X_{n})\})$$

$$= 1 - \alpha$$

für alle $\theta \in \Theta$



Sei $(\Omega,\{P_{\theta}\}_{\theta\in\Theta},\{X_j\}_{j\in\mathbb{N}})$ ein statistisches Modell und θ_j die j-te Komponente von $\theta=(\theta_1,\ldots,\theta_q)$.

(i) Es seien S_-, S_+ zwei Schätzer und $\alpha \in (0,1)$ eine (kleine) Irrtumswahrscheinlichkeit. Falls $S_- \leq S_+$ und

$$P_{\theta}(\theta_{j} \in (S_{-}, S_{+}])$$

$$= P_{\theta}(\{S_{-}(X_{1}, ..., X_{n}) < \theta_{j} \le S_{+}(X_{1}, ..., X_{n})\})$$

$$= 1 - \alpha$$

für alle $\theta \in \Theta$, dann heißt das paar S_-, S_+ ein **Intervallschätzer** für θ_j zum Konfidenzniveau $1 - \alpha$.



(ii) Das zufallsabhängige Intervall

$$(S_{-}(X_1,\ldots,X_n),S_{+}(X_1,\ldots,X_n)]$$

nennen wir auch **Konfidenzintervall** für θ_i zum Konfidenzniveau $(1 - \alpha)$.



Einfacher Fall:

Satz

Seien X_j i.i.d. mit $X_j \sim N(\mu, \sigma^2)$ mit bekannter Varianz σ^2 und sei $\theta = \mu \in \mathbb{R}$ der zu schätzenden Parameter.



Einfacher Fall:

Satz

Seien X_j i.i.d. mit $X_j \sim N(\mu, \sigma^2)$ mit bekannter Varianz σ^2 und sei $\theta = \mu \in \mathbb{R}$ der zu schätzenden Parameter. Mit dem p-Quantil z_p der von N(0,1), erhält man

(i) Das symmetrische, beidseitige Konfidenzintervall zum Konfidenzniveau $1-\alpha$ für den Erwartungswert μ mit gegebener Varianz σ^2 ist definiert durch

$$S_{\pm}(X_1,\ldots,X_n) = \bar{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}.$$



(ii) Das linksoffene, einseitige Konfidenzintervall zum Konfidenzniveau $1-\alpha$ für den Erwartungswert μ mit gegebener Varianz σ^2 ist definiert durch

$$S_{-} = -\infty, \quad S_{+}(X_{1}, \dots, X_{n}) = \bar{X} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$



(ii) Das linksoffene, einseitige Konfidenzintervall zum Konfidenzniveau $1-\alpha$ für den Erwartungswert μ mit gegebener Varianz σ^2 ist definiert durch

$$S_{-} = -\infty, \quad S_{+}(X_{1}, \dots, X_{n}) = \bar{X} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$

Gleiches gilt für das rechtsoffene, einseitige Konfidenzintervall

$$S_{+} = \infty, \quad S_{-}(X_{1}, \dots, X_{n}) = \bar{X} - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}.$$



Für unabhängige Z.V. $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$ gilt

$$X + Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$$



- lacktriangle Für unabhängige Z.V. $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$ gilt
- Induktiv folgt $X+Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$ $n \bar{X} \sim N(n \mu, n \sigma^2)$



- Für unabhängige Z.V. $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$ gilt
- Induktiv folgt $\begin{array}{c} X+Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2) \\ n\bar{X} \sim N(n\mu, n\sigma^2), \quad \text{also} \quad \bar{X} \sim N(\mu, \frac{1}{n}\sigma^2) \end{array}$



- Für unabhängige Z.V. $X \sim N(\mu_X, \sigma_X^2)$, $Y \sim N(\mu_Y, \sigma_Y^2)$ gilt
- Induktiv folgt $\begin{array}{c} X+Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2) \\ n\bar{X} \sim N(n\mu, n\sigma^2), \quad \text{also} \quad \bar{X} \sim N(\mu, \frac{1}{n}\sigma^2) \end{array}$

Damit

$$P\left(\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \le \mu < \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right)$$
$$= P\left(Z - z_{1-\alpha/2} \le 0 < Z + z_{1-\alpha/2},\right)$$

wobei $\mu = \mathbb{E}[X_1]$ den wahren Erwartungswert bezeichne (Standartisierung auf $Z \sim N(0,1)$).



▶ Wegen $-z_{1-\alpha/2} = z_{\alpha/2}$ erhalten wir

$$P(Z-z_{1-\alpha/2} \le 0 < Z + z_{1-\alpha/2})$$

$$= F(z_{1-\alpha/2}) - F(-z_{1-\alpha/2})$$

$$= 1 - \frac{\alpha}{2} - \frac{\alpha}{2}$$

$$= 1 - \alpha$$

mit der Verteilung F von N(0,1).



(ii)

Wieder Standartisieren:

$$P\left(\mu < \bar{X} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}\right) = P(0 < Z + z_{1-\alpha})$$

$$= P(-z_{1-\alpha} < Z)$$

$$= P(z_{\alpha} < Z)$$

$$= 1 - P(Z \le z_{\alpha})$$

$$= 1 - \alpha$$



(ii)

▶ Wieder Standartisieren:

$$P\left(\mu < \bar{X} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}\right) = P(0 < Z + z_{1-\alpha})$$

$$= P(-z_{1-\alpha} < Z)$$

$$= P(z_{\alpha} < Z)$$

$$= 1 - P(Z \le z_{\alpha})$$

$$= 1 - \alpha$$

Der linksoffene Fall geht analog.



▶ Beidseitige Konfidenzintervalle geben einen Vertrauensbereich, indem man mit sehr großer W.-keit $(1-\alpha)$ den wahren Wert findet. Man kann ihre (halbierte) Breite als typischen Schätzfehler auffassen.



- Beidseitige Konfidenzintervalle geben einen Vertrauensbereich, indem man mit sehr großer W.-keit $(1-\alpha)$ den wahren Wert findet. Man kann ihre (halbierte) Breite als typischen Schätzfehler auffassen.
- ▶ Einseitige Konfidenzintervalle geben eine obere/untere Schranke, die man mit sehr großer W.-keit (1α) nicht über-/unterschreitet.



- ▶ Beidseitige Konfidenzintervalle geben einen Vertrauensbereich, indem man mit sehr großer W.-keit $(1-\alpha)$ den wahren Wert findet. Man kann ihre (halbierte) Breite als typischen Schätzfehler auffassen.
- ▶ Einseitige Konfidenzintervalle geben eine obere/untere Schranke, die man mit sehr großer W.-keit (1α) nicht über-/unterschreitet.
- ▶ Typische Werte: $\alpha = 10\%, 5\%, 1\%$ oder 0.1%



- ► Eine Abfüllanlage füllt Limonade in Flaschen mit
 - einer Ungenauigkeit (= σ) von 0.01 l und
 - einem Füllmengen-Sollwert von 0.751



- ► Eine Abfüllanlage füllt Limonade in Flaschen mit
 - einer Ungenauigkeit (= σ) von 0.01 l und
 - einem Füllmengen-Sollwert von 0.751
- ► Fragestellung: Liegt die tatsächliche durchschnittliche Füllmenge unter 0.751 l?



- ► Eine Abfüllanlage füllt Limonade in Flaschen mit
 - \blacksquare einer Ungenauigkeit (= σ) von 0.01 l und
 - einem Füllmengen-Sollwert von 0.751
- ► Fragestellung: Liegt die tatsächliche durchschnittliche Füllmenge unter 0.751 l?
- ▶ Stichprobe mit 10 Flaschen liefert durchschnittliche Füllmenge von $\bar{x} = 0.749$ l.



- ► Eine Abfüllanlage füllt Limonade in Flaschen mit
 - einer Ungenauigkeit (= σ) von 0.01 l und
 - einem Füllmengen-Sollwert von 0.751
- ► Fragestellung: Liegt die tatsächliche durchschnittliche Füllmenge unter 0.751 l?
- ▶ Stichprobe mit 10 Flaschen liefert durchschnittliche Füllmenge von \bar{x} =0.749 l.
- ► Kann man mit 99%-iger Sicherheit sagen, dass der tatsächliche Durchschnittswert unter 0.751 liegt?



▶ Wir nehmen an, die Füllmenge X ist normalverteilt mit bekanntem $\sigma_X = 0.01$ und unbekanntem μ_X .



- ▶ Wir nehmen an, die Füllmenge X ist normalverteilt mit bekanntem σ_X =0.01 und unbekanntem μ_X .
- Wir berechnen das linksoffene Konfidenzintervall:



- ▶ Wir nehmen an, die Füllmenge X ist normalverteilt mit bekanntem $\sigma_X = 0.01$ und unbekanntem μ_X .
- Wir berechnen das linksoffene Konfidenzintervall: mit $z_{0.99}=2.33$ wissen wir, dass zu 99% der wahre Wert μ_X kleiner ist als

$$\bar{x} + z_{0.99} \frac{\sigma_X}{\sqrt{n}} = 0.749 + 2.33 \frac{0.01}{\sqrt{10}} = 0.756$$
.



- ▶ Wir nehmen an, die Füllmenge X ist normalverteilt mit bekanntem $\sigma_X = 0.01$ und unbekanntem μ_X .
- Wir berechnen das linksoffene Konfidenzintervall: mit $z_{0.99}=2.33$ wissen wir, dass zu 99% der wahre Wert μ_X kleiner ist als

$$\bar{x} + z_{0.99} \frac{\sigma_X}{\sqrt{n}} = 0.749 + 2.33 \frac{0.01}{\sqrt{10}} = 0.756$$
.

▶ Das 1%-Konfidenzintervall $(-\infty, 0.756)$ enthält 0.751



- ▶ Wir nehmen an, die Füllmenge X ist normalverteilt mit bekanntem $\sigma_X = 0.01$ und unbekanntem μ_X .
- Wir berechnen das linksoffene Konfidenzintervall: mit $z_{0.99}=2.33$ wissen wir, dass zu 99% der wahre Wert μ_X kleiner ist als

$$\bar{x} + z_{0.99} \frac{\sigma_X}{\sqrt{n}} = 0.749 + 2.33 \frac{0.01}{\sqrt{10}} = 0.756$$
.

- ▶ Das 1%-Konfidenzintervall $(-\infty, 0.756)$ enthält 0.751
- ▶ Wir können also nicht mit 99%-iger Sicherheit sagen, dass der Wert kleiner 0.751 l, da die statistische Streuung bei einer derart kleinen Stichprobe zu groß ist.



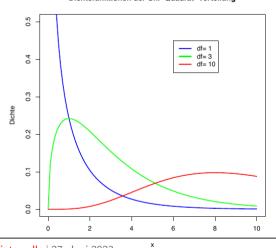
Seien X_1, \ldots, X_n i.i.d. mit $X_i \sim N(0, 1)$. Sei weiter

$$K^2 = K^2(X_1, \dots, X_n) = \sum_{j=1}^n X_j^2$$
.

Dann ist die χ^2 -Verteilung mit n Freiheitsgraden definiert als $\mathrm{Vert}(K^2)$.



Dichtefunktionen der Chi-Quadrat-Verteilung





Im Gauß-Produktmodell $P_{\theta}^{(n)}=N(\mu,\sigma^2)^{\otimes n}$ mit zu schätzenden Parametern $\theta=(\mu,\sigma^2)\in\mathbb{R}\times\mathbb{R}_+=\Theta$ sind das arithmetische Mittel \bar{X} und die empirische Varianz σ^2 unabhängig. Es gilt

$$Z = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N(0, 1)$$

und

$$(n-1)\frac{\hat{\sigma}^2}{\sigma^2} = (n-1)\frac{\hat{\sigma}^2(X_1, \dots, X_n)}{\sigma^2} \sim \chi(n-1).$$



Seien X,Y ZV'n mit $X\sim N(0,1)$ und $Y\sim \chi^2(n)$. Dann definiert die Verteilung der Zufallsvariable

$$T = \sqrt{n} \frac{X}{\sqrt{Y}} \sim t(n)$$

die Student-t-Verteilung zu n Freiheitsgraden.



Seien X,Y ZV'n mit $X\sim N(0,1)$ und $Y\sim \chi^2(n)$. Dann definiert die Verteilung der Zufallsvariable

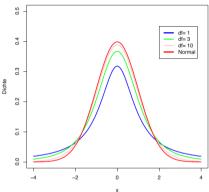
$$T = \sqrt{n} \frac{X}{\sqrt{Y}} \sim t(n)$$

die Student-t-Verteilung zu n Freiheitsgraden.

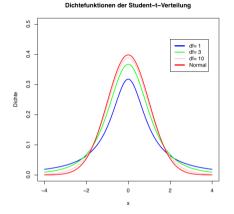
Diese wird die Rolle von N(0,1) beim Schätzen der Varianz übernehmen.

Technische Universität Berlin

Dichtefunktionen der Student-t-Verteilung



Technische Universität Berlin



Symmetrisch: für p < 0.5 gilt wieder $-t_p(n) = t_{1-p}(n)$



Es seien wie oben X_1, \ldots, X_n i.i.d. Zufallsvariablen mit $X_j \sim N(\mu, \sigma^2)$. Dann ist $T = T(X_1, \ldots, X_n)$

$$T = \sqrt{n} \frac{\bar{X} - \mu}{\hat{\sigma}}$$

Student-t-verteilt mit n-1 Freiheitsgraden, $T \sim t(n-1)$.



Es seien wie oben X_1, \ldots, X_n i.i.d. Zufallsvariablen mit $X_j \sim N(\mu, \sigma^2)$. Dann ist $T = T(X_1, \ldots, X_n)$

$$T = \sqrt{n} \frac{\bar{X} - \mu}{\hat{\sigma}}$$

Student-t-verteilt mit n-1 Freiheitsgraden, $T \sim t(n-1)$.

Beweis: Wir rechnen

$$T = \sqrt{n} \frac{\bar{X} - \mu}{\hat{\sigma}} = \sqrt{n - 1} \frac{\sqrt{n} \frac{\bar{X} - \mu}{\sigma}}{\sqrt{(n - 1) \frac{\hat{\sigma}^2}{\sigma^2}}} = \sqrt{n - 1} \frac{Z}{\sqrt{K^2}}.$$



Seien, für $j=1,\ldots,n$, X_j normalverteilte i.i.d. Zufallsvariablen $X_j\sim N(\mu,\sigma^2)$ und $\theta=(\mu,\sigma^2)\in\mathbb{R}\times\mathbb{R}_+=\Theta$ die im Produktmodell zu schätzenden Parameter. Mit $t_p(n-1)$, dem p-Quantil der Student-t-Verteilung mit n-1 Parametern, erhält man

(i) Das symmetrische, beidseitige Konfidenzintervall zum Konfidenzniveau $1-\alpha$ für den Erwartungswert μ mit geschätzter Varianz ist definiert durch

$$S_{\pm}(X_1,\ldots,X_n) = \bar{X} \pm t_{1-\alpha/2}(n-1)\frac{\hat{\sigma}}{\sqrt{n}}.$$



(ii) Das linksoffene, einseitige Konfidenzintervall zum Konfidenzniveau $1-\alpha$ mit geschätzter Varianz ist definiert durch $S_-=-\infty$ und

$$S_{+}(X_{1},...,X_{n}) = \bar{X} + t_{1-\alpha}(n-1)\frac{\hat{\sigma}}{\sqrt{n}}.$$

und es ist ebenfalls ein Konfidenzintervall.

Gleiches gilt für das rechtsoffene, einseitige Konfidenzintervall mit $S_+ = \infty$ und

$$S_{-}(X_{1},...,X_{n}) = \bar{X} - t_{1-\alpha}(n-1)\frac{\hat{\sigma}}{\sqrt{n}}$$
.



Der Beweis ist analog zum Beweis für die Konfidenzintervalle im Gauß-Fall.

- $ightharpoonup \sigma \rightarrow \hat{\sigma}$,
- $ightharpoonup Z \sim N(0,1) \rightarrow T \sim t(n-1)$ und
- ▶ Quantile von N(0,1)
 - \rightarrow entsprechende Quantile von t(n-1)



Mittlerer Ertrag von Maisanbauflächen (in Einheiten von ha) wird untersucht:

■ Stichprobengröße: n = 30■ Mittlerer Ertrag: $\hat{\mu} = 25 \, \mathrm{t}$

 \blacksquare empirische Standardabweichung: $\hat{\sigma} = 5 \, \mathrm{t}$



- ▶ Mittlerer Ertrag von Maisanbauflächen (in Einheiten von ha) wird untersucht:
 - Stichprobengröße: n = 30
 - Mittlerer Ertrag: $\hat{\mu} = 25\,\mathrm{t}$
 - lacktriangle empirische Standardabweichung: $\hat{\sigma} = 5 \, \mathrm{t}$
- ▶ Gibt es ein Konfidenzintervall, sodass der wahre Wert μ für den zu erwartenden Maisertrag mit 95% W.-keit in diesem Intervall liegt?



- ▶ Mittlerer Ertrag von Maisanbauflächen (in Einheiten von ha) wird untersucht:
 - Stichprobengröße: n = 30
 - Mittlerer Ertrag: $\hat{\mu} = 25\,\mathrm{t}$
 - \blacksquare empirische Standardabweichung: $\hat{\sigma} = 5 \, \mathrm{t}$
- ▶ Gibt es ein Konfidenzintervall, sodass der wahre Wert μ für den zu erwartenden Maisertrag mit 95% W.-keit in diesem Intervall liegt?

Lösung:

▶ Mit dem 2.5%-Quantil $t_{1-\alpha/2}(n-1)=t_{0.975}(n-1)=2.045$ der t(n-1)=t(29)-Verteilung erhalten wir das 95%-Konfidenzintervall

$$\left[\bar{x} - t_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} - t_{1-\alpha/2} \frac{\hat{\sigma}}{\sqrt{n}}\right] = [23.1, 26.9].$$