

# Stochastik für Info

## Statistische Modelle und ihre Kalibrierung

Hanno Gottschalk

June 21, 2023

<b>Statistische Modelle</b>	<b>3</b>
Was muß ein 'statistisches Modell' leisten? . . . . .	4
Statistische Modelle . . . . .	5
<b>Beispiele für Statistische Modelle</b>	<b>6</b>
Das Produktmodell . . . . .	7
Das Produktmodell - univariates Beispiel . . . . .	8
Das Produktmodell - univariates Beispiel . . . . .	9
<b>Zufallsvariable – Statistik – Schätzer</b>	<b>10</b>
Zufallsvariable und Statistik . . . . .	11
Statistik und Punktschätzer . . . . .	12
Eigenschaften von Punktschätzern . . . . .	13
Erwartungstreue der Empirischen Varianz . . . . .	14
Erwartungstreue der Empirischen Varianz II . . . . .	15
Bias und asymptotische Erwartungstreue . . . . .	16
Konsistenz von Schätzern . . . . .	17
MSE - Mean Square Error . . . . .	18
<b>Das Maximum Likelihood Prinzip</b>	<b>19</b>
Das Maximum Likelihood Prinzip . . . . .	20
Argmax und Argmin . . . . .	21
Maximum Likelihood Schätzer - Definition . . . . .	22
Likelihood und Log-Likelihood . . . . .	23
Unabhängige Wiederholungen . . . . .	24
Maximum Likelihood Gleichungen . . . . .	25
Maximum-Likelihood-Gleichungen II . . . . .	26
Beispiel . . . . .	27
<b>Log-Likelihood und Kullback-Leibler Information</b>	<b>28</b>
KL-Information . . . . .	29
Jensensche Ungleichung . . . . .	30
Beweis eind. Minimum für die KL-Info. . . . .	31

<b>Konsistenz von Maximum Likelihood</b>	<b>32</b>
Welche Rolle spielt die KL-Info? . . . . .	33
Mathematische Feinheiten . . . . .	34
<b>Numerische Beispiele</b>	<b>35</b>
ML für die Weibullverteilung . . . . .	36
Numerische Lösung . . . . .	37
Konvergenz zu KL. . . . .	38
Konsistenz in der Simulation I. . . . .	39

## Inhaltsverzeichnis der Vorlesung

- Statistische Modelle
- Zufallsvariable – Statistik – Schätzer
- Gute Eigenschaften von Parameterschätzern
- Das Maximum Likelihood Prinzip
- Log-Likelihood und Kullback-Leibler Information
- Numerische Beispiele

Hanno Gottschalk

Stochastik für Informatiker – 2 / 39

## Statistische Modelle

3 / 39

### Was muß ein 'statistisches Modell' leisten?

- Begrifflicher Rahmen für stochastischen Ausgang von Zufallsexperimenten
- (Unabhängige) Wiederholung von (identischen) Zufallsexperimenten
- Modell für Stichprobe und Daten (uni- und multivariat)
- Vorauswahl für vermutete Verteilungsfamilie
- Anpassung der 'am besten passenden' Verteilung aus der Familie
- Konzept für Validierung der Vorauswahl

Hanno Gottschalk

Stochastik für Informatiker – 4 / 39

## Statistische Modelle

**Def.** Ein *statistisches Modell* ist gegeben durch

- Eine Ereignismenge  $\Omega$
- Zufallsvariablen  $X, \dots, X_n : \Omega \rightarrow \mathbb{R}^d$  oder  $\rightarrow \mathbb{Z}^d$  oder andere Zustandsräume
- Eine Familie von W-Maßen  $P_\theta$  auf  $\Omega$  mit Parameterraum  $\theta \in \Theta$

**Bemerkung:** Anstelle der W-Maße werden zumeist die Verteilungsfunktionen/Dichten  $F_{X,\theta} / f_{X,\theta}$  angegeben für

$$F_{X,\theta}(x) = P_\theta(X_{i,j} \leq x_{i,j} \forall i,j) \quad X = \begin{pmatrix} X_{1,1} & \cdots & X_{1,d} \\ \vdots & \ddots & \vdots \\ X_{n,1} & \cdots & X_{n,d} \end{pmatrix}$$

Hanno Gottschalk

Stochastik für Informatiker – 5 / 39

## Beispiele für Statistische Modelle

6 / 39

### Das Produktmodell

**Def.:** Im *Produktmodell* modellieren wir die unabhängige Wiederholung von Zufallsexperimenten unter denselben Rahmenbedingungen.

Nehmen an, dass  $X_j \sim F_{X,\theta}$  und (Unabhängigkeit der Zufallsexperimente – nicht der Merkmale!)

$$F_{X,\theta}(x) = F_{(X_1, \dots, X_n)', \theta}(x_{1,1}, \dots, x_{n,d}) = \prod_{j=1}^n F_{X,\theta}(x_j)$$


bzw. dasselbe für Dichten (hier kontinuierlich)

$$f_{X,\theta}(x) = f_{(X_1, \dots, X_n)', \theta}(x_{1,1}, \dots, x_{n,d}) = \prod_{j=1}^n f_{X,\theta}(\underline{x}_j)$$

Hanno Gottschalk

Stochastik für Informatiker – 7 / 39

## Das Produktmodell - univariates Beispiel



Huhn legt an einem Tag mit W-keit  $p$  ein Ei oder nicht (W-keit  $1 - p$ )

$n = 200$  Hühner im Stall

Hanno Gottschalk

Stochastik für Informatiker – 8 / 39

## Das Produktmodell - univariates Beispiel

- $\Omega = \{0, 1\}^{\times 200}$ ,  $\omega = (0, 1, 1, 1, 0, \dots) = (\omega_1, \omega_2, \dots)$
- $\Theta = [0, 1]$ ,  $\theta = p$ ,  $P_p(\omega) = p^{\sum \omega_i} (1 - p)^{n - \sum \omega_i}$
- $X_j(\omega) = \omega_j$  Legeerfolg Huhn  $j$  ( $\omega_j \in \{0, 1\}$ )
- $f_{X,p}(0) = (1 - p)$ ,  $f_{X,p}(1) = p$  diskrete Dichte
- Dichtefunktion

$$\begin{aligned} f_{\underline{X},p}(x_1, \dots, x_{200}) &= \begin{cases} p^{\sum x_i} (1 - p)^{n - \sum x_i} & x \in \{0, 1\}^{\times 200} \\ 0 & x \in \mathbb{Z}^{200} \text{ sonst} \end{cases} \\ &= \begin{cases} \prod_{j=1}^n p^{x_j} (1 - p)^{1 - x_j} & x \in \{0, 1\}^{\times 200} \\ 0 & \text{sonst} \end{cases} \end{aligned}$$

Hanno Gottschalk

Stochastik für Informatiker – 9 / 39

## Zufallsvariable und Statistik

**Def.** Eine *Statistik* ist mathematisch einfach eine Zufallsvariable  $S : \Omega \rightarrow \mathbb{R}$  (Messbarkeit weggelassen).

Warum unterscheidet man 'Zufallsvariable' und 'Statistik'?

Begriffe zwar math. identisch, aber mit unterschiedlicher Interpretation!

**Zufallsvariable:** Ergebnis von Zufallsexperiment  $\rightarrow$  'Datensatz'

**Statistik:** Möglichst aussagekräftige Kenngröße, die auf *mehreren* Datensätzen beruht

**Beispiel Statistik:** arith. Mittel von Z.V.:  $\bar{X} = \frac{X_1 + \dots + X_n}{n}$ .

Hanno Gottschalk

Stochastik für Informatiker – 11 / 39

## Statistik und Punktschätzer

**Def.** Ein *Punktschätzer* ist eine Statistik, die speziell der Bestimmung eines Parameters  $\theta_i$  eines statistischen Modells mit Parametern  $\theta = (\theta_1, \dots, \theta_q) \in \Theta$  dient.

**Beispiel:** Das arithmetische Mittel  $\bar{Y}$  von  $Y$  ist im lin. Modell zwar stets eine wichtige Statistik, im allgemeinen aber *kein* Punktschätzer für  $\underline{\beta}$ .

Hanno Gottschalk

Stochastik für Informatiker – 12 / 39

## Eigenschaften von Punktschätzern

**Def.:** In einem Stat. Modell heißt ein Punktschätzer  $S : \Omega \rightarrow \mathbb{R}$  heißt *erwartungstreu* für einen Parameter  $\theta_i$ , wenn

$$\mathbb{E}_\theta[S] = \theta_i, \quad \forall \theta = (\theta_1, \dots, \theta_i, \dots, \theta_q) \in \Theta \quad (1)$$

$\mathbb{E}_\theta$  ist Erwartungswert bezüglich  $P_\theta$

**Beispiel:** Gegeben sei das univariate Produktmodell  $X \sim N(\mu, \sigma^2)$  (oder andere Vert. mit  $\mu$  als Parameter), dann ist  $\bar{X}$  ein erwartungstreuer Schätzer für  $\mu$

**Denn:**

$$\mathbb{E}_{\mu, \sigma^2} \left[ \frac{X_1 + \dots + X_n}{n} \right] = \frac{\mathbb{E}_{\mu, \sigma^2}[X_1] + \dots + \mathbb{E}_{\mu, \sigma^2}[X_n]}{n} = \frac{n\mu}{n} = \mu$$

Hanno Gottschalk

Stochastik für Informatiker – 13 / 39

## Erwartungstreue der Empirischen Varianz

Gegeben sei das univariate Produktmodell  $X \sim N(\mu, \sigma^2)$  (oder andere Vert. mit der Varianz  $\sigma^2$  als Parameter), dann ist  $\hat{\sigma}^2$  erwartungstreuer Schätzer für  $\sigma^2$

$$\hat{\sigma}^2 = \hat{\sigma}^2(X_1, \dots, X_n) = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2 \quad (2)$$

$$\begin{aligned} (n-1)\mathbb{E}_{\mu, \sigma^2}[\hat{\sigma}^2] &= \sum_{j=1}^n \mathbb{E}_{\mu, \sigma^2} \left[ ((X_j - \mu) - (\bar{X} - \mu))^2 \right] \\ &= \sum_{j=1}^n \left\{ \mathbb{E}_{\sigma^2, \mu}[(X_j - \mu)^2] + \mathbb{E}_{\sigma^2, \mu}[(\bar{X} - \mu)^2] \right. \\ &\quad \left. - 2\mathbb{E}[(X_j - \mu)(\bar{X} - \mu)] \right\} \end{aligned}$$

Hanno Gottschalk

Stochastik für Informatiker – 14 / 39

## Erwartungstreue der Empirischen Varianz II

$$\begin{aligned} &= \sum_{j=1}^n \left[ \sigma^2 + \frac{\sigma^2}{n} - 2\text{Cov}(X_j, \bar{X}) \right] \\ &= (n+1-2)\sigma^2 = (n-1)\sigma^2 \end{aligned}$$

**Denn:**

$$\begin{aligned} \text{Cov}(X_j, \bar{X}) &= \frac{1}{n} \sum_{k=1}^n \text{Cov}(X_j, X_k) \\ &= \frac{1}{n} \sigma^2 \end{aligned}$$

**qed.**

Normierung  $1/(n-1)$  nicht  $1/n$  !!!!

Hanno Gottschalk

Stochastik für Informatiker – 15 / 39

## Bias und asymptotische Erwartungstreue

**Def.:** Der *Bias* (Verzerrung) eines Schätzers  $S$  für  $\theta_i$  in einem statistischen Modell ist

$$\text{Bias}_\theta(S) = \mathbb{E}_\theta[S] - \theta_i, \quad \theta = (\theta_1, \dots, \theta_i, \dots, \theta_q) \in \Theta \quad (3)$$

Der Bias ist der *systematische Schätzfehler*

**Def.** Ein Schätzer  $S$  (oder genauer eine Schätzerfamilie  $S_n$ ) heißt *asymptotisch Erwartungstreu*, wenn

$$\text{Bias}_\theta(S) = \text{Bias}_\theta(S_n) \longrightarrow 0 \text{ für } n \rightarrow \infty \quad (4)$$

**Beispiel:**  $\frac{1}{n} \sum_{j=1}^n (X_j - \bar{X})^2$  ist asymptotisch Erwartungstreu für  $\sigma^2$ , denn der Bias ist  $-\frac{\sigma^2}{n}$ .

Hanno Gottschalk

Stochastik für Informatiker – 16 / 39



## Konsistenz von Schätzern

**Def.:** Ein Schätzer  $S$  (oder genauer eine Schätzerfamilie  $S_n$ ) für den Parameter  $\theta_i$  heißt *konsistent*, wenn  $S_n \rightarrow \theta_i$  nach Wahrscheinlichkeit

$$P(|S_n - \theta_i| > \epsilon) \rightarrow 0 \text{ für } n \rightarrow \infty \quad \forall \epsilon > 0$$

**Beispiel:**  $\bar{X}$  ist konsistent für  $\mu$  (schwaches Gesetz der gr. Zahlen)

**Es gilt:**  $S_n$  asymptotisch erwartungstreu und  $\text{Var}(S_n) \rightarrow 0 \Rightarrow S_n$  ist konsistent.

**Beweis:**  $\epsilon > 0$  und  $n > n_0$  so dass  $|\text{Bias}(S_n)| < \epsilon/2 \Rightarrow$

$$\begin{aligned} P(|S_n - \theta_i| > \epsilon) &\leq P(|S_n - \mathbb{E}[S_n]| + |\text{Bias}_\theta(S_n)| > \epsilon/2 + \epsilon/2) \\ &\leq P(|S_n - \mathbb{E}[S_n]| > \epsilon/2) \leq \frac{4\text{Var}(S_n)}{\epsilon^2} \rightarrow 0 \end{aligned}$$

Hanno Gottschalk

Stochastik für Informatiker – 17 / 39

## MSE - Mean Square Error

**Def.:** Der MSE eines Schätzers  $S$  (oder genauer einer Schätzerfamilie  $S_n$ ) ist definiert als

$$\text{MSE}_\theta(S) = \mathbb{E}_\theta[(S_n - \theta_i)^2] \quad (5)$$

**Es gilt die Bias-Varianz-Zerlegung:**

$$\text{MSE}_\theta(S) = \text{Var}_\theta(S) + \text{Bias}_\theta(S)^2 \quad (6)$$

**Denn: vgl. Skript Einf. Stoch.**

**Es gilt:** Falls für einen Schätzer  $S$  gilt  $\text{MSE}(S) \rightarrow 0 \Rightarrow S$  ist konsistent.

**Denn:** Der Schätzer ist dann asymptotisch Erwartungstreu und die Varianz verschwindet für  $n \rightarrow \infty$

Hanno Gottschalk

Stochastik für Informatiker – 18 / 39

## Das Maximum Likelihood Prinzip

- Beobachte Daten  $x_1, \dots, x_n$  aus Zufallsexperiment
- Habe statistisches Modell  $P_\theta^{(n)}$ ,  $\theta \in \Theta$ , für die Verteilung der  $n$ -fachen Wiederholung des Z.E. .
- Unter allen möglichen Modellen  $P_\theta^{(n)}$  wähle dasjenige, welches den **beobachteten Daten**  $x_1, \dots, x_n$  die höchste W.-keit zuordnet.

Dies kann als eine Schätzprozedur verstanden werden:

$$\hat{\theta}_{ML} = \hat{\theta}_{ML}(x_1, \dots, x_n) = \arg \max_{\theta \in \Theta} P_\theta(\{(x_1, \dots, x_n)\}) \quad (7)$$

Hanno Gottschalk

Stochastik für Informatiker – 20 / 39

## Argmax und Argmin

**Def.:** Das argmax einer Funktion  $f : \Theta \rightarrow \mathbb{R}$  ist definiert als

$$\arg \max_{\theta \in \Theta} f(\theta) = \{\theta^* \in \Theta : f(\theta^*) \geq f(\theta) \forall \theta \in \Theta\} \quad (8)$$

Analog gilt für das argmin

$$\arg \min_{\theta \in \Theta} f(\theta) = \{\theta^* \in \Theta : f(\theta^*) \leq f(\theta) \forall \theta \in \Theta\} \quad (9)$$

- Das argmax und argmin sind i.A. Mengen, d.h. mehrere Lösungen (oder keine) sind möglich
- Ist  $f$  stetig und  $\Theta$  kompakt, so gibt es mindestens eine Lösung
- Sind argmin/argmax eindeutig, so identifiziere die Menge mit ihrem einzigen Element.

Hanno Gottschalk

Stochastik für Informatiker – 21 / 39

## Maximum Likelihood Schätzer - Definition

**Def.:**  $P_\theta^{(n)}$ ,  $\theta \in \Theta$ , sei ein statistisches Modell für das  $n$ -fach durchgeführte Zufallsexperiment  $X_1, \dots, X_n$ .

(i) Sind die  $X_j$  diskret verteilt, so heißt eine Z.V.  $\hat{\theta}_{ML}$  Maximum-Likelihood-Schätzer, falls

$$\hat{\theta}_{ML} = \hat{\theta}_{ML}(X_1, \dots, X_n) \in \arg \max_{\theta \in \Theta} P_\theta(\{(X_1, \dots, X_n)\}). \quad (10)$$

(ii) Sind die  $X_j$  kontinuierlich verteilt mit gemeinsamer Dichte  $f(x_1, \dots, x_n|\theta)$ , so heißt eine Z.V.  $\hat{\theta}_{ML}$  Maximum-Likelihood-Schätzer, falls

$$\hat{\theta}_{ML} = \hat{\theta}_{ML}(X_1, \dots, X_n) \in \arg \max_{\theta \in \Theta} f(X_1, \dots, X_n|\theta). \quad (11)$$

Hier setzen wir nicht unbedingt die unabhängige oder identische Wiederholung der Zufallsexperimente voraus.

Hanno Gottschalk

Stochastik für Informatiker – 22 / 39

## Likelihood und Log-Likelihood

**Def.:** Die **Likelihood** des statistischen Modells  $P_\theta^{(n)}$ , gegeben die Daten  $x_1, \dots, x_n$  ist gegeben durch

$$\mathcal{L}(x_1, \dots, x_n|\theta) = \begin{cases} P_\theta(\{(x_1, \dots, x_n)\}) & \text{falls } X_j \text{ diskret} \\ f(x_1, \dots, x_n|\theta) & \text{falls } X_j \text{ kontinuierlich} \end{cases} \quad (12)$$

Der Logarithmus ist eine streng monoton steigende Funktion  $\Rightarrow$  (kontinuierlicher Fall)

$$\arg \max_{\theta \in \Theta} f(X_1, \dots, X_n|\theta) = \arg \max_{\theta \in \Theta} \log(f(X_1, \dots, X_n|\theta)) \quad (13)$$

**Def.** Die log-Likelihood ist definiert als der Logarithmus der Likelihood-Funktion.

Hanno Gottschalk

Stochastik für Informatiker – 23 / 39

## Unabhängige Wiederholungen

Wir betrachten den Spezialfall, dass  $X_1, \dots, X_n$  unabhängig voneinander sind.

Insbesondere gilt im Produktmodell

$$\log \mathcal{L}(x_1, \dots, x_n | \theta) = \sum_{j=1}^n \log f(x_j | \theta) \quad (14)$$

Hanno Gottschalk

Stochastik für Informatiker – 24 / 39

## Maximum Likelihood Gleichungen

Wie löst man das Optimierungsproblem in  $\theta$ ?

- Ableiten in  $\theta$ , Null setzen und Auflösen (ML-Gleichungen)
- Numerische Optimierungsmethoden

**Def.:** Die Maximum-Likelihood Gleichungen sind gegeben durch  
( $k = 1, \dots, q$ ,  $\theta = (\theta_1, \dots, \theta_q)$ ):

$$0 = \frac{\partial}{\partial \theta_k} \log \mathcal{L}(x_j | \theta) = \sum_{j=1}^n \frac{\partial}{\partial \theta_k} \log f(x_j | \theta), \quad (15)$$

Die score-Funktion ist gegeben als  $l'(y|x, \theta) = \nabla_{\theta} l(x|y, \theta)$  mit  $l(x|\theta) = \log f(x|\theta)$ .

Hanno Gottschalk

Stochastik für Informatiker – 25 / 39

## Maximum-Likelihood-Gleichungen II

Also können die ML-Gleichungen auch äquivalent über die Score-Funktionen formuliert werden:

Im Produktmodell gilt:

$$0 = \sum_{j=1}^n l'(x_j|\theta), \quad l(x, \theta) = \log f(x|\theta),$$

$$l'(x, \theta) = \nabla_{\theta} l(x, \theta) = \nabla_{\theta} \log f(x|\theta) = \frac{\nabla_{\theta} f(x|\theta)}{f(x|\theta)}.$$

Hanno Gottschalk

Stochastik für Informatiker – 26 / 39

## Beispiel

$X_j \sim \text{Exp}(\lambda)$  sei exponentialverteilt,  $x_1, \dots, x_n$  Messwerte.

$$f(x|\lambda) = \lambda e^{-\lambda x}, \quad x > 0.$$

$$l(x|\lambda) = \log(\lambda) - \lambda x$$

$$l'(x|\lambda) = \frac{1}{\lambda} - x$$

$$0 = \sum_{j=1}^n \left[ \frac{1}{\lambda} - x_j \right] = \frac{n}{\lambda} - n\bar{x}$$

$$\hat{\lambda}_{ML} = \frac{1}{\bar{x}}$$

Hanno Gottschalk

Stochastik für Informatiker – 27 / 39

**KL-Information**

**Def.:** Gegeben sei ein statistisches Modell, das der Einfachheit halber mit kontinuierlichen Dichten  $X_j \sim f(x, \theta)$  i.i.d. angenommen wird (Rechnungen für diskrete Dichte analog),  $\theta \neq \theta' \Rightarrow f(\cdot|\theta) \neq f(\cdot|\theta')$  (als  $L^1$ -fkt.)

Die Kullback-Leibler Information ist gegeben durch

$$\begin{aligned} K(\theta_0|\theta) &= -\mathbb{E}_{\theta_0} \left[ \log \left( \frac{f(X|\theta)}{f(X|\theta_0)} \right) \right] \\ &= - \int \log \left( \frac{f(x|\theta)}{f(x|\theta_0)} \right) f(x|\theta_0) dx \end{aligned} \quad (16)$$

**Satz:**  $K(\theta_0|\theta) \geq 0$  und Gleichheit gilt genau dann wenn  $\theta = \theta_0$ .

Hanno Gottschalk

Stochastik für Informatiker – 29 / 39

**Jensensche Ungleichung**

$\log(t)$  ist strikt konkav  $\Rightarrow -\log(t)$  ist strikt konvex.

**Lemma:** (Jensensche Ungleichung)

$Y$  reelwertige Z.V.  $F$  konvex  $\Rightarrow$

$$\mathbb{E}[F(Y)] \geq F(\mathbb{E}[Y])$$

Ist  $F$  strikt konvex,  $F'' > 0$ , dann gilt Gleichheit genau dann wenn  $Y = c$  fast sicher ( $Y$  deterministisch).

**Bew.:** Siehe Skript Einf. Stochastik.

Hanno Gottschalk

Stochastik für Informatiker – 30 / 39

## Beweis eind. Minimum für die KL-Info

Anwendung:  $Y = \frac{f(X|\theta)}{f(X|\theta_0)} \Rightarrow$

$$\begin{aligned} K(\theta_0|\theta) &= \mathbb{E}_{\theta_0}[-\log(Y)] \geq -\log(\mathbb{E}_{\theta_0}[Y]) \\ &= -\log\left(\int \frac{f(x|\theta)}{f(x|\theta_0)} f(x|\theta_0) dx\right) \\ &= -\log\left(\int f(x, \theta) dx\right) = -\log(1) = 0 \end{aligned}$$

Gleichheit gilt genau dann (Jensen) wenn  $\frac{f(x|\theta)}{f(x|\theta_0)} = c \Leftrightarrow f(x|\theta) = cf(x|\theta_0)$ .

Es muss gelten  $c = 1$  (Normiertheit des Integrals über beide W.-keitsdichten), also

$$f(x|\theta) = f(x|\theta_0) \Rightarrow \theta = \theta_0 \quad \text{qed.}$$

Hanno Gottschalk

Stochastik für Informatiker – 31 / 39

## Konsistenz von Maximum Likelihood

32 / 39

### Welche Rolle spielt die KL-Info?

**Beobachtung:** Sei wieder  $P_{\theta}^{(n)}$  das Produktmodell zu  $X_j \sim f(x|\theta_0)$ .

D.h.  $\theta_0$  ist der wahre Parameter.

$$\begin{aligned} &\arg \max_{\theta \in \Theta} \mathcal{L}(X_1, \dots, X_n|\theta) \\ &= \arg \max_{\theta \in \Theta} \log \mathcal{L}(X_1, \dots, X_n|\theta) \\ &= \arg \max_{\theta \in \Theta} \frac{1}{n} \log \mathcal{L}(X_1, \dots, X_n|\theta) \\ &= \arg \max_{\theta \in \Theta} \frac{1}{n} (\log \mathcal{L}(X_1, \dots, X_n|\theta) - \log \mathcal{L}(X_1, \dots, X_n|\theta_0)) \\ &= \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{j=1}^n [l(X_j|\theta) - l(X_j|\theta_0)] \\ &\stackrel{?}{\rightarrow} \arg \max_{\theta \in \Theta} \mathbb{E}_{\theta_0} [\log f(X|\theta) - \log f(X|\theta_0)] = -K(\theta_0|\theta) = \theta_0 \end{aligned}$$

Hanno Gottschalk

Stochastik für Informatiker – 33 / 39

## Mathematische Feinheiten

Warum das Fragezeichen?

Zwar konvergiert die (redefinierte) log-Likelihood-Funktion gegen (minus) die KL-Information für jedes  $\theta, \theta_0 \dots$

Die minus KL-Info hat 1-deutiges Maximum in  $\theta = \theta_0 \dots$

Aber dürfen wir  $\arg \max$  und Grenzwert ( $\rightarrow$ ) einfach vertauschen?

Ja, unter geeigneten Voraussetzungen!

Hanno Gottschalk

Stochastik für Informatiker – 34 / 39

## Numerische Beispiele

35 / 39

### ML für die Weibullverteilung

Betrachten das Weibull-Produktmodell

$$f(x|\theta) = f(x|\eta, m) = \left(\frac{m}{\eta}\right) \left(\frac{x}{\eta}\right)^{m-1} \exp \left\{ - \left(\frac{x}{\eta}\right)^m \right\}.$$

$$l(x|\theta) = l(x|\eta, m) = \log \left(\frac{m}{\eta}\right) + (m-1) \log \left(\frac{x}{\eta}\right) - \left(\frac{x}{\eta}\right)^m$$

$$\log \mathcal{L}(x_1, \dots, x_n|\eta, m) = \sum_{j=1}^n l(x_j|\eta, m)$$

Hanno Gottschalk

Stochastik für Informatiker – 36 / 39



## Numerische Lösung

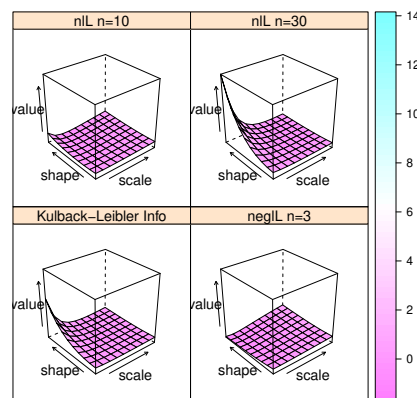
Da die ML-Gleichungen des Weibull-Produktmodells keine geschlossene Lösung haben, verwenden wir ein Verfahren mit numerischer Optimierung:

```
n=100                                     # set number of
                                         # Wei(2,2) Pseudos
theta0=c(2,2)                             # set  $\theta_0$ 
nlL=function(theta,X) -sum(dweibull(X,    # def.
scale=theta[1],shape=theta[2],log=TRUE)) # negLogLikelihood
X=rweibull(n,scale=theta0[1],shape=theta0[2]) # generate sample
thetaS=c(1,1)                             # set start as Exp(1)
optim(thetaS,nlL,X=X)                     # calculate estimate
                                         # by optimization of  $\theta$ 
```

Hanno Gottschalk

Stochastik für Informatiker – 37 / 39


## Konvergenz zu KL



Hanno Gottschalk

Stochastik für Informatiker – 38 / 39

## Konsistenz in der Simulation I



Hanno Gottschalk

Stochastik für Informatiker – 39 / 39